উত্তর — পরিকল্পনার প্রশ্নাবলি (২৮-০৮-২০২৬)

এই ফোল্ডারের হাতে-লেখা ৬টি প্রশ্নের (`WhatsApp Image 2026-08-28 at 10.56.24/25 PM.jpeg`) উত্তর, বর্তমান repo-র অবস্থার ভিত্তিতে তৈরি: SPRINT_PLAN.md, planning/plan.md, এবং doc/README.md।

প্রশ্ন ১। এই week এ ডেটাসেট বানাবো, তারপর Preprocess করব — আমরা আসলে কি করতে চাচ্ছি?

Repo-তে আসলে **দুটো আলাদা ট্র্যাক** আছে, একটা না — আর এই প্রশ্নটা মূলত "এই সপ্তাহের ডেটাসেট কোন ট্র্যাকের অন্তর্গত" সেটাই জানতে চাওয়া:

- **ট্র্যাক A — পুরনো থিসিস থেকে পেপার** (SPRINT_PLAN.md): ডেটাসেট (১,৬১৭ রেকর্ড) এবং সবগুলো (৩২টা) imputation×clustering পাইপলাইন **আগে থেকেই শেষ** (BUBT ক্যাপস্টোন থেকে carry-over হয়ে এসেছে)। এই ট্র্যাকে **নতুন করে ডেটা সংগ্রহের দরকার নেই** — এটা মূলত একটা ১৪-দিনের লেখা/সোর্সিং/ফরম্যাটিং স্প্রিন্ট (১৭ আগস্ট → ৩০ আগস্ট, ২০২৬), যেখানে ওই শেষ হওয়া কাজটাকে একটা জমাযোগ্য কনফারেন্স/জার্নাল পেপারে রূপান্তর করা হচ্ছে।
- **ট্র্যাক B — নতুন অটোমেটেড ডেটা পাইপলাইন** (planning/plan.md): একটা একদম নতুন, **এখনো তৈরি হয়নি এমন** পাইপলাইন, যেটা প্রথম আলোর আত্মহত্যা-সংক্রান্ত সংবাদ automatically সংগ্রহ করবে (আগের এক-এক করে HTML ম্যানুয়ালি সেভ করার ধাপটার বদলে), Claude দিয়ে গঠনমূলক (structured) ফিল্ড বের করবে, এবং একটা নতুন `suicide_data.csv` তৈরি করবে। "এই সপ্তাহে ডেটাসেট বানাবো, তারপর Preprocess করব" — এই কথাটা এই ট্র্যাকেরই অংশ।

উত্তর: "এই সপ্তাহের ডেটাসেট" মানে ট্র্যাক B (অটোমেটেড harvest → classify → extract → build পাইপলাইন, `data-collection/`-এ)। Preprocessing (cleaning, imputation ইত্যাদি) হলো এই ডেটাসেট তৈরি হওয়ার *পরের* ধাপ — অনেকটা ক্যাপস্টোন আগে পুরনো ডেটাসেটের উপর যা করেছিল তারই পুনরাবৃত্তি, তবে এবার নতুন ও automatically সংগৃহীত ডেটাসেটের উপর। ট্র্যাক A (পেপার) সমান্তরালে চলবে এবং এটা ট্র্যাক B শেষ হওয়ার উপর নির্ভর করে না।

প্রশ্ন ২। আমরা region wise কিছু করব, নাকি suicide এর কারণ (reason) নিয়ে করব? মোট কথা, আমাদের goal কি?

এটা either/or না — `planning/plan.md`-এ যে schema ডিজাইন করা হচ্ছে, সেটা ইতিমধ্যেই **দুটোই** ধরে রেখেছে:

- কারণ (Reason): `reason` (নির্দিষ্ট ক্যাটাগরি) + `reason_description` (মুক্ত টেক্সট) + `_evidence_reason`
- অঞ্চল (Region): `hometown` + `latitude`/`longitude` (`bd_districts.csv` গেজেটিয়ার এর মাধ্যমে)

উত্তর: সামগ্রিক লক্ষ্য (ক্যাপস্টোন থিসিসের শিরোনাম অনুযায়ী, *"A Machine Learning Approach to Identifying Influential Factors and Clustering Patterns in Suicide Occurrences"*) হলো **প্রভাবক বিষয়গুলো (influential factors)** চিহ্নিত করা — যার মধ্যে কারণ, ডেমোগ্রাফিক্স, *এবং* ভৌগোলিক অবস্থান — সবই পড়ে, এবং সেগুলোর মধ্যে **clustering patterns** খুঁজে বের করা। Region-wise আর reason-wise — দুটোই সেই একই clustering/factor বিশ্লেষণের ইনপুট, একটা আরেকটার প্রতিদ্বন্দ্বী লক্ষ্য না। ডেটা-সংগ্রহের ধাপে একটাকে বেছে নেওয়ার দরকার নেই; দুটো column-ই একসাথে সংগ্রহ করা হবে।

প্রশ্ন ৩। আমরা যেটা করতে চাচ্ছি, তার উপর একটা brief দিতে হবে

খসড়া brief (প্রয়োজনে পরে পরিমার্জনযোগ্য):

> এই প্রজেক্টে বাংলাদেশি সংবাদপত্রে (প্রথম আলো) প্রকাশিত আত্মহত্যার ঘটনাগুলোর একটা গঠনমূলক (structured) ডেটাসেট তৈরি ও বিশ্লেষণ করা হচ্ছে — একটা LLM-ভিত্তিক extraction পাইপলাইনের মাধ্যমে স্বয়ংক্রিয়ভাবে

> ডেমোগ্রাফিক, ভৌগোলিক এবং প্রাসঙ্গিক তথ্য (কারণ, পদ্ধতি, অবস্থান) বের করে — যা আগের সম্পূর্ণ ম্যানুয়াল সংগ্রহ প্রক্রিয়ার জায়গা নিচ্ছে। ফলে তৈরি হওয়া ডেটাসেট ব্যবহার করা হবে বাংলাদেশে আত্মহত্যার ঘটনায় প্রভাবক বিষয় ও clustering pattern চিহ্নিত করতে — যা আগের BUBT ক্যাপস্টোন কাজের (১,৬১৭ রেকর্ড, ৩২টা imputation×clustering পাইপলাইন ইতিমধ্যে সম্পন্ন, সেরা পাইপলাইন: Agglomerative Clustering + MissForest, composite score ২৭.৩০/৩২) একটা সম্প্রসারণ — নতুন অটোমেটেড পাইপলাইন একটা পাইলট ব্যাচে যাচাই হওয়ার পর একটা আপডেটেড, বড় ২০১৬–২০২৬ ডেটাসেট দিয়ে।

প্রশ্ন ৪। Existing paper গুলো পড়ে, তারপর কি করব সেটা select করে title দিব। কিন্তু ডাটা collect করার আগেই title দেওয়া — এটা একটু confusion...

এটা গবেষণা প্রক্রিয়ার একটা স্বাভাবিক অংশ, কোনো স্ববিরোধিতা না:

- এই পর্যায়ে দেওয়া শিরোনাম একটা **working title** (কার্যকরী/অস্থায়ী শিরোনাম), চূড়ান্ত না — এটা literature review-এর ভিত্তিতে উদ্দিষ্ট scope/method বলে দেয়, এবং ফলাফল আসার পর পরিমার্জিত হয় (এটাই standard practice — জার্নালগুলো আশা করে যে চূড়ান্ত শিরোনাম চূড়ান্ত ফলাফলের সাথে মিলবে, উল্টোটা না)।
- এই প্রজেক্টের একটা স্বাভাবিক অ্যাঙ্কর আগে থেকেই আছে: ক্যাপস্টোন থিসিসের বর্তমান শিরোনাম, *"A Machine Learning Approach to Identifying Influential Factors and Clustering Patterns in Suicide Occurrences"*। যদি নতুন এই ডেটা-সংগ্রহের কাজটা ওই কাজেরই একটা **সম্প্রসারণ (extension)** হয় (বড়/আপডেটেড ডেটাসেট, একই factors/clustering পদ্ধতি), তাহলে working title সেই শিরোনামেরই একটা variant হতে পারে (যেমন "an updated dataset" বা তারিখ পরিসর যোগ করে) — নতুন কিছু আবিষ্কার করার দরকার নেই ডেটা আসার আগেই।

উত্তর: এখনই literature review + বিদ্যমান থিসিস শিরোনাম থেকে একটা working title ঠিক করে ফেলুন, এবং নতুন ডেটাসেট + বিশ্লেষণ শেষ হলে সেটা আবার revisit করুন — শিরোনাম চূড়ান্ত করার জন্য ডেটা সংগ্রহ আটকে রাখার দরকার নেই।

প্রশ্ন ৫। ডাটা collect এর বিষয়টা মূল্যায়ন করতে অনেক টাইম লাগবে — Automatic কিভাবে করা যায়?

এটাই ঠিক যা planning/plan.md-তে ইতিমধ্যে ডিজাইন করা হয়েছে। বর্তমান অবস্থা: `data-collection/codebase/extract_suicide_data.py` শুধু **ম্যানুয়ালি সেভ করা** HTML ফাইল এক-এক করে হ্যান্ডেল করে (`input/1.html`, `2.html` → এখন পর্যন্ত ২টা row) — এটাই সবচেয়ে ধীর অংশ।

পরিকল্পিত সমাধান, সম্পূর্ণ automatable, চারটা ধাপে:

১. **`01_harvest.py`** — প্রথম আলোর search API-তে সরাসরি `requests` কল (live `curl` টেস্ট করে নিশ্চিত করা হয়েছে: headless browser-এর দরকার নেই), paginated, resumable, URL দিয়ে deduped। এক পাসেই title/link/date/পূর্ণ body text সংগ্রহ করে। ২. **`02_classify.py`** — সস্তা heuristic-ভিত্তিক প্রাসঙ্গিকতা (relevance) ফিল্টার (প্রতিটা "আত্মহত্যা" হিট আসল ঘটনার রিপোর্ট না — কিছু আদালতের মামলা, সিনেমার রিভিউ, মতামত/opinion কলাম হতে পারে)। ৩. **`03_extract_fields.py`** — শুধু প্রাসঙ্গিক আর্টিকেলগুলোর cached text Claude-এ পাঠায়, কঠোর "শুধু স্পষ্টভাবে বলা তথ্যই বের করো, না হলে null" prompt দিয়ে (`doc/3_field_extractor.py` থেকে adapt করা), checkpointed — যাতে মাঝপথে crash/interrupt হলে আগে-প্রসেস-করা আর্টিকেলগুলোর জন্য আবার বিল না হয়। ৪. **`04_build_database.py`** — সবকিছু জোড়া দিয়ে চূড়ান্ত CSV তৈরি করে, cached intermediate ফাইল থেকে সম্পূর্ণ regeneratable, কখনো হাতে এডিট করা হবে না।

উত্তর: হ্যাঁ, পুরোটাই end-to-end automate করা সম্ভব। বাকি থাকা একমাত্র ম্যানুয়াল সময়ের খরচ হলো **QA** (মান-যাচাই), সংগ্রহ না — প্রথমে পাইপলাইনটা প্রায় ২০০টা আর্টিকেলে সীমাবদ্ধ রেখে চালান, extract করা কিছু রেকর্ড source আর্টিকেলের সাথে মিলিয়ে spot-check করুন, তারপর cap সরিয়ে পুরো harvest চালান — যেভাবে `planning/plan.md`-তে verification plan-এ আগে থেকেই লেখা আছে।

প্রশ্ন ৬। আপনাদের আগের Paper টা কতটুকু করেছেন, এটা বুঝায় দিয়েন

SPRINT_PLAN.md অনুযায়ী:

- **সম্পন্ন (১০০%):** ডেটাসেট (১,৬১৭ রেকর্ড), সবগুলো (৩২টা) imputation×clustering পাইপলাইন, পূর্ণ ফলাফল — এটাই শেষ হওয়া BUBT ক্যাপস্টোন থিসিস (~১,৪৭,০০০ ক্যারেক্টার, ৬টা অধ্যায়, ৪২-এন্ট্রির রেফারেন্স তালিকা)। সেরা ফলাফল: Agglomerative Clustering + MissForest (no-context), composite score ২৭.৩০/৩২, একটা two-cluster সমাধান যা স্বাভাবিকভাবেই ডেটা-সংগ্রহের cohort অনুযায়ী আলাদা হয়ে গিয়েছিল (২০২০ বনাম ২০১৭–২০২৫)।
- **বাকি আছে:** ওই শেষ হওয়া থিসিসকে একটা জমাযোগ্য কনফারেন্স/জার্নাল পেপারে রূপান্তর করা — একটা ১৪-দিনের লেখা/সোর্সিং/ফরম্যাটিং স্প্রিন্ট (২০২৬-০৮-১৭ → ২০২৬-০৮-৩০), যার মধ্যে আছে venue/template নির্বাচন, একটা আসল `refs.bib` তৈরি করা (থিসিসের ৪২টা + নতুন সাহিত্যের ৯টা রেফারেন্স), থিসিসের সবগুলো ৬টা অধ্যায়কে পেপারের section-এ সংক্ষিপ্ত করা, বিদ্যমান নোটবুক থেকে figure/table বের করা, এবং সহলেখক/সুপারভাইজারের রিভিউ।
- **আজ (২০২৬-০৮-২৮) আমরা কোথায় আছি:** ১৪ দিনের মধ্যে ১২তম দিন — নির্ধারিত **internal review** দিন (খসড়াটা সহলেখক ও সুপারভাইজার, মো. মামুন হোসেনের কাছে পাঠিয়ে read-through করানো, এবং নতুন যোগ করা সাহিত্যের বিপরীতে novelty framing-টা sanity-check করানো)।