পেপার আউটলাইন — উত্তর (ক্যাপস্টোন থেকে পেপার রূপান্তর)

৯টি আইটেমের উত্তর, সহজ ভাষায়, নেওয়া হয়েছে `prior-work/newly formated capstone report 2025.docx`, `SPRINT_PLAN.md`, এবং ক্যাপস্টোন নোটবুক/CSV থেকে। এটি একটি রেফারেন্স নোট, আসল পেপার নয় — আসল ম্যানুস্ক্রিপ্ট থাকবে `paper/sections/` এর ভেতরে, `SPRINT_PLAN.md` অনুযায়ী।

(ইংরেজি সম্পূর্ণ ভার্সন: `planning/paper-outline-answers.md`)

এখনো সিদ্ধান্ত বাকি (টিমকে ঠিক করতে হবে, রিপো থেকে বের করা যায় না)

- **রেকর্ড সংখ্যার গরমিল**: থিসিসের লেখায় বলা আছে **১,৬১৭**টি রেকর্ড; কিন্তু আসল CSV ফাইলে (`prior-work/SuicideBD-dataset - SuicideBD-dataset.csv`) আছে **১,৭৯৭**টি ডেটা রো। পেপারে দেওয়ার আগে কোনটা সঠিক তা নিশ্চিত করতে হবে।
- **কে কোন অংশ লিখবে** — এটা রিপোর কোথাও লেখা নেই। `SPRINT_PLAN.md`-এর দিন-ভিত্তিক কাজ অনুযায়ী ভাগ করে নেওয়া যেতে পারে।

১. শিরোনাম (Title)

"A Machine Learning Approach to Identifying Influential Factors and Clustering Patterns in Suicide Occurrences" — এটাই বর্তমান থিসিসের শিরোনাম (`Capstone_Project_Report.zip` → `cover_page.tex`)।

ছোট, পেপার-স্টাইল বিকল্প: *"Clustering Bangladeshi Suicide Incidents from Incomplete Newspaper Data."*

২. সাহিত্য পর্যালোচনা (Literature review)

বাংলাদেশ/দক্ষিণ এশিয়ার আত্মহত্যা নিয়ে আগের কাজগুলো হয় কেসের সংখ্যা গোনে (এপিডেমিওলজি), নয়তো টেক্সট থেকে ঝুঁকি শনাক্ত করে (সোশ্যাল মিডিয়া/নোটের ওপর NLP)। কেউ বাংলাদেশের জন্য একটা বড়, সমৃদ্ধ আত্মহত্যা-ডেটাসেট বানিয়ে ঠিকভাবে মিসিং-ডেটা হ্যান্ডলিং ও ক্লাস্টারিং করেনি। এই স্টাডি ঠিক সেই ফাঁকটা পূরণ করে — এটা স্ট্রাকচার্ড ডেটা নিয়ে কাজ করে, ফ্রি-টেক্সট নিয়ে নয়।

৩. এই রিভিউয়ের সীমাবদ্ধতা (Limitations)

১. **ডেটা সোর্স বায়াস** — শুধু পত্রিকায় রিপোর্ট হওয়া সম্পন্ন আত্মহত্যার ঘটনা, গ্রামীণ/লুকানো কেসগুলো বাদ পড়ে যায়। ২. **ডেটাসেটের আকার সীমিত** — ১,৬১৭ রেকর্ড এখন পর্যন্ত সবচেয়ে বড় কিউরেটেড ডেটাসেট, কিন্তু ML-এর জন্য এখনও ছোট, এবং অনেক জায়গায় ডেটা মিসিং। ৩. **সব সম্ভাব্য সেটিং টেস্ট করা হয়নি** — প্রতিটি অ্যালগরিদমের জন্য হাইপারপ্যারামিটারের পুরো রেঞ্জ টেস্ট করা হয়নি। ৪. **এক্সটার্নাল ভ্যালিডেশন নেই** — পুরোপুরি আনসুপারভাইজড, ক্লাস্টারগুলো সঠিক কিনা যাচাই করার মতো কোনো গ্রাউন্ড-ট্রুথ লেবেল নেই। ৫. **বাংলা ফ্রি-টেক্সট কলাম বাদ** — `profession_description` এবং `reason_description` (বাংলা টেক্সট) বাদ দেওয়া হয়েছে, কারণ NLP টুল ছিল না। ৬. **অসম্পূর্ণ আবহাওয়া ডেটা** — গ্রামীণ স্টেশনগুলোর জন্য Meteostat-এর কভারেজ কম, তাই আবহাওয়া-সংক্রান্ত ভ্যারিয়েবলগুলো অনেকটাই অসম্পূর্ণ থেকে গেছে।

৪. ব্যবহৃত অ্যালগরিদম ও মডেল

দুই ধাপে কাজ হয়েছে: প্রথমে, মিসিং ডেটা তিনভাবে পূরণ করা হয়েছে (MICE, KNN, MissForest), প্রতিটা দুই ধরনের প্রেডিক্টর স্ট্র্যাটেজি দিয়ে। এরপর রেকর্ডগুলোকে চারভাবে গ্রুপ করা হয়েছে (K-Means, Agglomerative, DBSCAN, Spectral)। মোট

৩২টি কম্বিনেশন টেস্ট করা হয়েছে। সবচেয়ে ভালো ফলাফল: **MissForest (no-context) দিয়ে পূরণ করা ডেটায় Agglomerative clustering**।

৫. ডেটাসেট (Dataset)

পত্রিকা থেকে সংগ্রহ করা বাংলাদেশি আত্মহত্যার ঘটনার রেকর্ড (মূলত Dhaka Tribune-ভিত্তিক), ২০১৭–২০২৫ সাল কভার করে। আগের ৭৬০-কেসের ডেটাসেটের সাথে ৮৫৭টি নতুন কেস এবং ৯টি নতুন অ্যাট্রিবিউট যোগ করে বড় করা হয়েছে। থিসিসের লেখায় ১,৬১৭ রেকর্ডের কথা বলা আছে; কিন্তু CSV ফাইলে ১,৭৯৭টি রো আছে (ওপরে "সিদ্ধান্ত বাকি" অংশ দেখুন)।

৬. ডেটা প্রসেসিং

পত্রিকার কাঁচা ডেটায় ক্লাস্টারিং করার আগে অনেক মিসিং ভ্যালু ছিল (কিছু কলামে ৯০%-এরও বেশি)। মিসিং ভ্যালুগুলো তিনটি স্ট্যাটিস্টিক্যাল পদ্ধতিতে পূরণ করা হয়েছে, প্রতিটা এক্সট্রা কনটেক্সট সহ ও ছাড়া — যার ফলে ক্লাস্টারিং চালানোর জন্য ডেটাসেটের ৮টি ভার্সন তৈরি হয়েছে।

৭. কর্ম-পরিকল্পনা (Working plan)

`SPRINT_PLAN.md`-এ দিন-ভিত্তিক পুরো প্ল্যান লেখা আছে। ২০২৬-০৮-২৯ অনুযায়ী, প্রজেক্টটি ১৪ দিনের মধ্যে **১৩তম দিনে** আছে — এখন প্রুফরিডিং এবং পেপারটা থিসিসের "ডুপ্লিকেট পাবলিকেশন" হয়ে যাচ্ছে কিনা তা চেক করার সময়। ১৪তম দিন (২০২৬-০৮-৩০) হলো ফাইনাল পলিশ ও সাবমিশনের দিন।

৮. আমরা কী করতে যাচ্ছি

ইতিমধ্যে শেষ হওয়া থিসিসটাকে একটা ছোট, সাবমিট-করার-উপযোগী কনফারেন্স পেপারে রূপান্তর করা। নতুন কোনো এক্সপেরিমেন্ট লাগবে না — ডেটাসেট এবং ৩২টি পাইপলাইনের ফলাফল আগে থেকেই আছে। এটা মূলত লেখা ও ফরম্যাটিংয়ের কাজ, নতুন গবেষণা নয়।

৯. টিম, টুলস এবং প্রত্যাশিত ফলাফল

টিম: Mohammed Akash, Md Arifuzzan, Sajedul Islam, Komol Chandra Devnath, Anisul Haque Bhuiyan — সুপারভাইজার Md. Mamun Hossain (BUBT CSE)। কে কোন পেপার-সেকশন লিখবে তা এখনও ঠিক হয়নি (ওপরের "সিদ্ধান্ত বাকি" অংশ দেখুন)।

টুলস ও প্রযুক্তি: Google Colab নোটবুক, Python (pandas, numpy), আর বাকি সবকিছুর জন্য scikit-learn — মিসিং ভ্যালু পূরণের জন্য `KNNImputer` ও `IterativeImputer` (MICE), MissForest-এর জন্য `RandomForestRegressor`/`Classifier`, এবং গ্রুপিংয়ের জন্য `KMeans`, `AgglomerativeClustering`, `DBSCAN`, `SpectralClustering`। পেপারটা লেখা হবে LaTeX-এ।

উপসংহার / প্রত্যাশিত ফলাফল: পত্রিকার এলোমেলো, বেশিরভাগ-অসম্পূর্ণ ডেটা থেকেও সঠিক পদ্ধতির মিসিং-ডেটা-পূরণ ও ক্লাস্টারিং অ্যালগরিদমের কম্বিনেশন দিয়ে আসল, অর্থবহ প্যাটার্ন বের করে আনা সম্ভব। লক্ষ্যটা নতুন কোনো মেথড আবিষ্কার করা নয় — বরং বাংলাদেশে ইতিমধ্যে থাকা ডেটা ব্যবহার করে আত্মহত্যা প্রতিরোধে আরও প্রমাণ-ভিত্তিক (evidence-based) পদক্ষেপের দিকে একটা পদক্ষেপ নেওয়া।